

Wieloskalowa agentowa symulacja rozprzestrzeniania się pandemii wirusowej

Dawid Mularczyk¹

¹Informatyka, Akademia Górniczo-Hutnicza
muldaw@student.agh.edu.pl

2026

Streszczenie

Niniejszy dokument stanowi całościowy raport z projektu, którego celem jest zaprojektowanie i stopniowa implementacja symulacji agentowej (Agent-Based Model, ABM) rozprzestrzeniania się pandemii wirusowej w populacji miejskiej. Projekt zrealizowano w trzech etapach: (1) zaprojektowanie architektury i prototyp modelu SEIRD na siatce, (2) pełna implementacja heterogenicznego środowiska miejskiego opartego na węzłach POI (dom, szkoła, praca), mechanizmów transmisji oraz interaktywnego interfejsu użytkownika wraz z kalibracją i testami, (3) właściwy eksperyment badawczy porównujący siedem scenariuszy interwencji epidemicznych. Model zaimplementowano w Pythonie z użyciem frameworku Mesa; eksperymenty są w pełni odtwarzalne (stałe ziarna losowe). Współczynnik reprodukcji wyznaczono empirycznie dwiema niezależnymi metodami (odtworzenie krzywej $R_e(t)$ oraz relacja rozmiaru końcowego epidemii), otrzymując zgodne $R_0 \approx 1,9$, na dolnej granicy zakresu typowego dla pandemicznych wirusów oddechowych. Eksperyment wykazał m.in., że lockdown natychmiastowy redukuje attack rate z $\approx 80\%$ do $\approx 3,5\%$, że załedwie ≈ 9 -dniowe opóźnienie reakcji zwiększa zasięg epidemii blisko czterokrotnie, oraz że realistyczny pakiet łagodnych interwencji (maseczki, higiena, częściowe szczepienia) tłumi epidemię niemal tak skutecznie jak lockdown reaktywny, lecz bez zamykania miejsc pracy.

Słowa kluczowe: modelowanie agentowe, epidemiologia obliczeniowa, model SEIRD, efektywne $R_e(t)$, transmisja chorób, Mesa, Python

1 Wstęp i przegląd aktualnego stanu badań

Zrozumienie i przewidywanie dynamiki rozprzestrzeniania się chorób zakaźnych jest jednym z kluczowych problemów współczesnej epidemiologii obliczeniowej i planowania polityki zdrowia publicznego [1]. Globalne kryzysy zdrowotne – od grypy hiszpanki w 1918 roku, przez epidemię wirusa Ebola, aż po pandemię COVID-19 – dobitnie pokazały, że komputerowe modele symulacyjne stanowią niezbędne narzędzie wspierające procesy decyzyjne: pozwalają testować scenariusze interwencji, prognozować obciążenie służby zdrowia oraz oceniać skuteczność działań prewencyjnych przed ich wdrożeniem w rzeczywistej populacji [8].

1.1 Klasyczne modele kompartmentowe

Historycznie dominującym podejściem były modele kompartmentowe oparte na układach nieliniowych równań różniczkowych zwyczajnych (ODE). Klasyczny model SIR [6] dzieli populację na trzy grupy: Podatnych (*Susceptible*), Zakaźnych (*Infectious*) oraz Wyzdrowiałych (*Recovered*). Dynamika przejść pomiędzy stanami opisana jest przez równania:

$$\frac{dS}{dt} = -\beta \frac{SI}{N}, \quad \frac{dI}{dt} = \beta \frac{SI}{N} - \gamma I, \quad \frac{dR}{dt} = \gamma I \quad (1)$$

gdzie β oznacza współczynnik transmisji, γ tempo zdrowienia, a N całkowitą liczebność populacji [3].

Pomimo wysokiej wydajności obliczeniowej, fundamentalnym ograniczeniem modeli ODE jest założenie o homogenicznym mieszanii się populacji: każdy osobnik ma równe prawdopodobieństwo kontaktu z każdym innym. Założenie to całkowicie ignoruje strukturę przestrzenną, klastry społeczne oraz indywidualne zachowania [4].

1.2 Modelowanie agentowe jako odpowiedź na ograniczenia ODE

Modelowanie oparte na agentach (ABM) reprezentuje populację jako zbiór autonomicznych jednostek, z których każda posiada własny zestaw atrybutów, wewnętrzny stan oraz reguły behawioralne [2]. Agenci oddziałują bezpośrednio ze sobą i ze środowiskiem w zdefiniowanej przestrzeni topologicznej. Mikroskopowe interakcje prowadzą do powstawania zjawisk emergentnych na poziomie makroskopowym, takich jak fale epidemiczne, lokalne ogniska zakażeń czy zdarzenia typu *superspreader* [9].

Kluczowe zalety podejścia agentowego w kontekście modelowania epidemii:

- uwzględnienie heterogeniczności populacji (wiek, zachowania, odporność),
- naturalne modelowanie struktur społecznych (rodzina, praca, szkoła),
- możliwość symulacji wielu dróg transmisji (powietrzna, dotyk, fomity),
- emergentne powstawanie zjawisk niemożliwych do przewidzenia przez ODE.

1.3 Cel i zakres projektu

Celem projektu jest zaprojektowanie i stopniowa implementacja wieloskalowej, hybrydowej symulacji agentowej pandemii wirusowej w środowisku miejskim. Platforma integruje mechanikę kompartmentową (model SEIRD) z pełną architekturą agentową, umożliwiając analizę wpływu zachowań indywidualnych, struktury przestrzeni miejskiej oraz różnorodnych interwencji epidemicznych na dynamikę zakażeń. Projekt realizowany jest w trzech etapach:

1. **Etap 1 – Model i wstępna implementacja:** projekt architektury, specyfikacja agentów i środowiska, prototyp działającej symulacji SEIRD.
2. **Etap 2 – Implementacja i wstępna weryfikacja:** pełna implementacja mechanizmów transmisji (aerozol, fomity), kalibracja parametrów, testy poprawności modelu.
3. **Etap 3 – Właściwy eksperyment i projekt końcowy:** przeprowadzenie scenariuszy badawczych, analiza wyników, wnioski końcowe.

2 Etap 1: Model i wstępna implementacja

Etap pierwszy obejmuje całościowe zaprojektowanie modelu epidemiologicznego, specyfikację architektury agentów i środowiska symulacyjnego, dobór stosu technologicznego oraz implementację działającego prototypu.

2.1 Model epidemiologiczny: SEIRD

W odróżnieniu od prostego modelu SIR, każdy agent w systemie przechodzi przez rozszerzony zestaw stanów klinicznych – model SEIRD – opisany równaniami:

$$S \xrightarrow{\lambda(t)} E \xrightarrow{\sigma} I \xrightarrow{\gamma} R, \quad I \xrightarrow{\mu} D \quad (2)$$

gdzie $\lambda(t)$ to zmienna w czasie siła zakażenia (zależna od kontaktów agenta), σ – tempo przejścia z okresu inkubacji do fazy zakaźnej, γ – tempo zdrowienia, a μ – wskaźnik śmiertelności.

Stany modelu:

- **S** (*Susceptible*) – agent podatny, bez odporności,
- **E** (*Exposed*) – agent w okresie inkubacji; zainfekowany, ale jeszcze niezakaźny (ruchliwy, nieświadomy zakażenia),
- **I** (*Infectious*) – agent czynnie zakaźny, wydalający patogen,
- **R** (*Recovered*) – agent wyleczony z nabytą odpornością,
- **D** (*Dead*) – agent, który nie przeżył infekcji.

Kluczowym elementem realizmu jest wprowadzenie ciągłego *ładunku wirusowego* (viral load) – wewnętrznej zmiennej agenta, która narasta pod koniec fazy E, osiąga szczyt na początku fazy I i maleje w miarę działania układu odpornościowego. Ładunek wirusowy bezpośrednio przekłada się na prawdopodobieństwo zakażenia innych agentów przy każdej interakcji.

Docelowo czasy trwania poszczególnych faz nie będą wartościami stałymi – zostaną pobrane z rozkładu Gamma, co pozwoli na odwzorowanie naturalnej wariancji biologicznej [7]. W prototypie MVP (Etap 1) czasy te są uproszczone do wartości stałych; rozkłady Gamma zostaną wprowadzone w Etapie 2 podczas kalibracji modelu.

2.2 Parametry patogenu bazowego

Modelowany patogen to hipotetyczny, agresywny wirus oddechowy o charakterystyce pośredniej między wirusem grypy pandemicznej a wirusem SARS-CoV-2. Tabela 1 zestawia planowane wartości parametrów wstępnych, które zostaną skalibrowane w Etapie 2.

2.3 Atrybuty agentów ludzkich

Każdy agent w systemie (HumanAgent) jest instancją klasy skupiającej trzy grupy atrybutów.

Tabela 1: Parametry epidemiologiczne modelowanego patogenu (wartości wstępne)

Parametr	Wartość	Źródło / podstawa
Bazowy współczynnik reprodukcji R_0	2,5 – 3,5	Grypa pandemiczna / COVID-19
Okres inkubacji (faza E)	Gamma($\mu=5d$, $\sigma=2d$)	[10]
Czas zakaźności (faza I)	Gamma($\mu=8d$, $\sigma=3d$)	[7]
Wskaźnik śmiertelności CFR	1,5% – 2,5% (wg wieku)	
Drogi transmisji	Aerozol, krople, fomity	
Odporność po przejściu choroby	6 – 12 miesięcy	

2.3.1 Atrybuty demograficzne i socjologiczne

- **Wiek** – pobierany z empirycznej piramidy demograficznej; determinuje przynależność do grupy funkcjonalnej (dziecko, dorosły, senior) i wzorce mobilności,
- **Identyfikator gospodarstwa domowego** – agenci z tego samego domu dzielą przestrzeń nocną; klastry domowe są jednym z najistotniejszych ognisk transmisji,
- **Miejsce pracy / szkoła** – przypisany węzeł POI, do którego agent regularnie się przemieszcza zgodnie z harmonogramem.

2.3.2 Atrybuty kliniczne i immunologiczne

- **Stan chorobowy** – aktualny kompartment SEIRD,
- **Ładunek wirusowy** – ciągła zmienna reprezentująca miano wirusa (używana przy obliczaniu ryzyka transmisji),
- **Profil odporności** – bazowa podatność biologiczna, modyfikowana przez wiek i historię szczepień; po przejściu fazy R nadawana jest tymczasowa lub stała pula przeciwciał,
- **Status szczepienia** – redukuje prawdopodobieństwo zakażenia i drastycznie zmniejsza ryzyko zgonu.

2.3.3 Atrybuty behawioralne

- **Harmonogram dzienny** (rutyna) – określa, w jakich godzinach symulacji agent opuszcza dom, przemieszcza się do pracy, odwiedza sklepy itp.,
- **Wskaźnik higieny** (Θ_H) – spersonalizowany współczynnik częstotliwości mycia rąk; aktywnie redukuje miano wirusa na dłoniach, minimalizując ryzyko samozakażenia i zanieczyszczania powierzchni,
- **Skłonność do kontaktów** – heterogeniczność liczby interakcji na dobę; agenci o wysokiej wartości tego parametru połączeni z wysokim ładunkiem wirusowym naturalnie przyjmują rolę *superspreaderów*.

Tabela 2 zawiera zestawienie wszystkich planowanych atrybutów klasy HumanAgent.

Tabela 2: Kluczowe atrybuty klasy HumanAgent

Atrybut	Typ / zakres	Rola w modelu
age	int, [0–100]	Mobilność, odporność, śmiertelność
household_id	int	Klasy domowe, nocna transmisja
workplace_id	int / None	Harmonogram, węzeł POI
state	enum SEIRD	Stan kliniczny agenta
viral_load	float [0–1]	Siła emisji patogenu
immunity	float [0–1]	Podatność na zakażenie
vaccinated	bool	Redukcja transmisji i zgonów
hygiene_score	float [0–1]	Mycie rąk, redukcja fomitów
contact_rate	float	Liczba interakcji / doba
daily_schedule	lista POI	Sekwencja węzłów w ciągu doby

2.4 Architektura środowiska: przestrzeń i węzły POI

Środowisko symulacyjne zorganizowane jest jako heterogeniczny graf $G = (V, E)$, gdzie V to zbiór fizycznych lokalizacji (*Points of Interest*, POI), a E – uproszczone ścieżki tranzytowe umożliwiające ruch pomiędzy nimi [4]. Węzły grafu podzielone są na semantyczne kategorie:

- **Gospodarstwa domowe** – przestrzeń nocna i poranna,
- **Miejsca pracy i biura** – codzienne docelowe węzły dla dorosłych,
- **Placówki edukacyjne** – szkoły i uczelnie dla dzieci i młodzieży,
- **Przestrzenie handlowe** – supermarkety, sklepy,
- **Obiekty rozrywkowe** – parki, restauracje,
- **Placówki ochrony zdrowia** – kliniki, szpitale.

Każdy węzeł POI posiada atrybuty środowiskowe wpływające na dynamikę aerozolu: pojemność, metraż, współczynnik wentylacji oraz temperaturę. Słabo wentylowane, gęsto zaludnione węzły (np. klasa szkolna, wagon metra) radykalnie zwiększają ryzyko transmisji aerozolowej w porównaniu z przestrzeniami otwartymi.

2.5 Transmisja wewnątrz węzłów POI

W modelu opartym na grafie POI transmisja chorób zachodzi wewnątrz węzłów – agent zakaźny może zainfekować innych agentów przebywających w tym samym budynku lub lokalizacji w danym kroku symulacji. Ryzyko zakażenia zależy od liczby agentów zakaźnych w węźle oraz charakterystyki samego miejsca (zagęszczenie, wentylacja, typ aktywności).

Prawdopodobieństwo, że podatny agent ulegnie zakażeniu w jednym kroku przy obecności I agentów zakaźnych w tym samym węźle, opisuje wzór [4]:

$$P_{\text{inf}} = 1 - (1 - p_{\text{base}})^I \quad (3)$$

gdzie p_{base} to bazowe prawdopodobieństwo zakażenia na jeden kontakt z zakaźnym agentem, zależne od typu węzła POI. Wzór odzwierciedla fakt, że każda kolejna osoba zakaźna obecna w tym samym miejscu niezależnie zwiększa ryzyko ekspozycji.

W docelowej implementacji (Etap 2, plik `transmission.py`) wzór ten rozszerzono o indywidualny ładunek wirusowy v_i każdego zakaźnego agenta i oraz odporność podatnego agenta, dając efektywne prawdopodobieństwo zakażenia w jednym kroku:

$$P_{\text{inf}} = \left(1 - \prod_{i \in \mathcal{C}} (1 - p_{\text{eff},i})^{v_i}\right) \cdot (1 - \text{immunity}) \quad (4)$$

gdzie $\mathcal{C}$ to zbiór (co najwyżej `MAX_INFECTIOUS_CONTACTS`, zob. Sekcja 3.3) wylosowanych zakaźnych sąsiadów, $p_{\text{eff},i}$ – prawdopodobieństwo zmodyfikowane przez maseczki, dystans i higienę (wzory (5) i (9)), a $v_i \in [0, 1]$ – ładunek wirusowy agenta i . Człon $(1 - \text{immunity})$ obniża ryzyko u osób zaszczepionych lub po przebytej infekcji.

Tabela 3 zestawia wartości p_{base} dla poszczególnych typów węzłów, uzasadnione różnicami w zagęszczeniu i czasie przebywania [10].

Tabela 3: Bazowe prawdopodobieństwo zakażenia p_{base} według typu węzła POI

Typ węzła POI	p_{base}	Uzasadnienie
Szkoła / klasa	0,30	Duże zagęszczenie, długi czas kontaktu
Biuro (open space)	0,20	Umiarkowane zagęszczenie, dzienny kontakt
Gospodarstwo domowe	0,35	Bliski, wielogodzinny kontakt
Sklep / supermarket	0,10	Krótki czas pobytu, rotacja klientów
Park / przestrzeń otwarta	0,03	Rozproszone kontakty, wentylacja naturalna
Placówka zdrowotna	0,15	Protokoły ochronne częściowo obniżają ryzyko

2.6 Behawioralne modyfikatory ryzyka

Kluczową zaletą podejścia agentowego jest możliwość modelowania interwencji poprzez zmianę zachowań jednostek, bez konieczności modyfikacji równań transmisji [8]. W modelu wprowadzone zostaną dwa atrybuty behawioralne wpływające na prawdopodobieństwo zakażenia.

Noszenie maseczki (`wears_mask`, wartość logiczna) – agent z maseczką redukuje zarówno emisję patogenu jako zakażony, jak i podatność na zakażenie jako agent podatny. Efektywny czynnik redukcji η_M stosowany jest do p_{base} :

$$p_{\text{eff}} = p_{\text{base}} \cdot \begin{cases} (1 - \eta_M)^2 & \text{obie strony w maseczce} \\ (1 - \eta_M) & \text{jedna strona w maseczce} \\ 1 & \text{brak maseczek} \end{cases} \quad (5)$$

Wartość $\eta_M = 0,5$ oznacza 50% redukcję ryzyka per kontakt, co jest zgodne z metaanalizami dotyczącymi chirurgicznych maseczek jednorazowych [10].

Dystans społeczny (`social_distancing`, wartość logiczna) – agent z aktywnym dystansem społecznym ogranicza liczbę odwiedzanych węzłów POI o wysokim ryzyku (pomija sklepy i miejsca rozrywki) i redukuje efektywną p_{base} o dodatkowe 20%.

Oba atrybuty są konfigurowane jako ułamki populacji objętej danym zachowaniem, co pozwala w Etapie 3 na przeprowadzenie eksperymentów z interaktywnym interfejsem: suwak „Procent populacji w maseczkach” generuje natychmiastową zmianę widoczną na krzywych epidemicznych.

2.7 Stos technologiczny

2.7.1 Język programowania i framework

Implementacja prowadzona jest w języku **Python** z użyciem frameworku **Mesa** [5] – otwartego standardu de facto dla modelowania agentowego w Pythonie. Mesa dostarcza:

- moduł harmonogramowania (RandomActivation) – losowe kolejowanie agentów eliminuje nierealistyczne wzorce deterministyczne,
- moduł przestrzenny (MultiGrid) – siatka umożliwiająca wielokrotne zajmowanie komórek przez agentów,
- DataCollector – automatyczne zbieranie zmiennych makroskopowych (S, E, I, R, D) do struktur pandas,
- rozszerzenie mesa-geo – integracja z systemami GIS / OpenStreetMap dla realistycznej topografii miejskiej.

2.7.2 Biblioteki pomocnicze

- **NumPy** – wektoryzowane obliczenia numeryczne (aktualizacja mian wirusowych dla tysięcy fomitów per tick),
- **pandas** – analiza i eksport wyników symulacji,
- **Matplotlib / Seaborn** – wizualizacja krzywych epidemicznych,
- **Streamlit** – interaktywny dashboard do sterowania parametrami i przeglądania wyników na żywo,
- **pytest** – automatyczne testy jednostkowe i integracyjne weryfikujące mechanikę kompartmentową.

2.7.3 Struktura projektu

Projekt organizowany jest zgodnie ze standardem *src layout*:

```

1 pandemic-simulation/
2 |-- pyproject.toml           # zaleznosci, metadane pakietu
3 |-- uv.lock                 # zamrozone wersje zaleznosci (reprodukowalne
   srodowisko)
4 |-- README.md
5 |-- configs/                # pliki YAML z parametrami patogenu
6 |   |-- pathogen_base.yaml
7 |   '-- scenario_lockdown.yaml
8 |-- data/
9 |   |-- input/              # piramidy demograficzne, grafy GIS
10 |   '-- output/             # wyniki DataCollector (CSV, JSON)

```

```

11 | -- src/
12 |   '-- simulation/
13 |       |-- __init__.py
14 |       |-- agents.py      # HumanAgent, FomiteAgent
15 |       |-- model.py       # EpidemicModel (rdzen Mesa)
16 |       |-- space.py       # graf POI, pathfinding
17 |       '-- transmission.py # mechanika aerozoli i fomitow
18 | -- tests/                # pytest, testy jednostkowe
19 | '-- scripts/             # CLI: uruchomienie, batch runs

```

Listing 1: Planowana struktura katalogów projektu

Separacja parametrów patogenu do plików konfiguracyjnych (YAML) od logiki rdzenia gwarantuje łatwą wymianę modelowanego wirusa (np. grypa vs. wariant SARS) bez modyfikowania kodu symulacji.

2.8 Prototyp MVP – implementacja

Zgodnie z zasadą stopniowego budowania złożoności, Etap 1 kończy się działającym prototypem minimalnym (MVP). Nie implementuje on jeszcze fomitów, grafu POI ani pełnego modelu aerozolowego – te mechanizmy zostaną dodane w Etapie 2. Celem MVP jest potwierdzenie, że model SEIRD generuje realistyczne krzywe epidemiczne (szczyt zakażonych, plateau wyzdrowiałych) oraz że architektura kodu jest poprawna.

Środowisko symulacyjne to siatka MultiGrid o rozmiarze 50×50 z topologią torusową. Na jednej komórce może przebywać wielu agentów. Agenci aktywowani są w każdym kroku w losowej kolejności (RandomActivation). Populacja startowa: $N = 500$ agentów, z czego 5% inicjalnie w stanie I.

Listing 2 przedstawia metodę `step()` klasy `HumanAgent`, która w każdym tiku wykonuje trzy akcje: ruch losowy, próbę zakażenia sąsiadów oraz progresję kliniczną.

```

1 def step(self) -> None:
2     if self.state == State.D:
3         return          # martwy agent nie wykonuje akcji
4
5     self._move()         # losowy ruch na sasiednie pole (Moore)
6
7     if self.state == State.I:
8         self._try_infect_neighbors() # p_inf = 0.20 per sasiad S
9
10    self._progress_disease() # przejscia E->I->R/D wg licznika dni
11    self.days_in_state += 1

```

Listing 2: Metoda `step()` klasy `HumanAgent` – rdzeń logiki agenta

Listing 3 pokazuje inicjalizację modelu z konfigurowalnymi parametrami oraz ustawienie `DataCollector` do śledzenia liczebności każdego kompartmentu.

```

1 self.datacollector = mesa.DataCollector(
2     model_reporters={
3         "S": lambda m: sum(1 for a in m.schedule.agents
4                             if a.state == State.S),
5         "E": lambda m: sum(1 for a in m.schedule.agents
6                             if a.state == State.E),
7         "I": lambda m: sum(1 for a in m.schedule.agents
8                             if a.state == State.I),

```

```

9         "R": lambda m: sum(1 for a in m.schedule.agents
10                             if a.state == State.R),
11         "D": lambda m: sum(1 for a in m.schedule.agents
12                             if a.state == State.D),
13     }
14 )

```

Listing 3: Inicjalizacja EpidemicModel i konfiguracja DataCollector

Tabela 4 zestawia parametry wejściowe prototypu MVP. Wartości te są celowo uproszczone – kalibracja do empirycznych danych epidemiologicznych jest zadaniem Etapu 2.

Tabela 4: Parametry prototypu MVP (Etap 1)

Parametr	Wartość	Znaczenie
n_agents	500	Liczebność populacji
width, height	50	Wymiary siatki
p_inf	0,20	Prawdopodobieństwo zakażenia na kontakt
incubation_period	4	Dni w stanie E przed przejściem do I
infectious_period	8	Dni w stanie I przed wyzdrow./zgonem
p_death	0,02	Prawdopodobieństwo zgonu po fazie I
initial_infected_frac	0,05	Frakcja agentów I na starcie

Symulację uruchamia się skryptem `scripts/run_simulation.py`, który iteruje model przez 100 kroków i generuje wykres krzywych epidemicznych SEIRD zapisywany do `data/output/epidemic_c`.

2.9 Weryfikacja prototypu: krzywe epidemiczne i wyznaczenie R_0

Rysunek 1 przedstawia krzywe epidemiczne uzyskane z jednokrotnego uruchomienia prototypu MVP przy parametrach z Tabeli 4.

Emergentny współczynnik reprodukcji R_0 wyznaczono analitycznie ze wzoru dla modelu siatkowego:

$$R_0 \approx p_{\text{inf}} \cdot \bar{k} \cdot T_I \quad (6)$$


gdzie $\bar{k}$ to oczekiwana liczba podatnych sąsiadów agenta zakaźnego, a T_I – czas zakaźności. Przy gęstości agentów $\rho = N/(W \cdot H) = 500/2500 = 0,20$ ag./komórkę i sąsiedztwie Moore’a (8 komórek):

$$\bar{k} = 8 \cdot \rho \cdot \frac{S_0}{N} = 8 \cdot 0,20 \cdot 0,95 \approx 1,52 \quad (7)$$

Podstawiając do równania (6):

$$R_0 \approx 0,20 \cdot 1,52 \cdot 8 \approx 2,4\text{--}2,6 \quad (8)$$

Wartość stochastyczna odczytana z symulacji wynosi $R_0 \approx 2,6$, co mieści się w przedziale analitycznym i potwierdza poprawność mechaniki zakażeń. Zgodność z danymi dla pandemicznych wirusów oddechowych ($R_0 \in [2,0; 3,5]$) stanowi pierwszą pozytywną weryfikację modelu.



Rysunek 1: Krzywe epidemiczne SEIRD prototypu MVP ($N = 500$, 100 kroków). Widoczny szczyt kompartmentu I (ok. dnia 25), plateau kompartmentu R oraz marginalna śmiertelność D zgodna z zadaniem $p_{\text{death}} = 0,02$.

3 Etap 2: Implementacja i wstępna weryfikacja

Etap drugi obejmuje pełną implementację wszystkich zaplanowanych w Etapie 1 mechanizmów oraz wstępną weryfikację poprawności modelu. Wynik: działający, skalibrowany model agentowy na grafie POI ze wszystkimi mechanizmami transmisji i interaktywnym interfejsem użytkownika.

3.1 Graf POI i skalowanie węzłów

Środowisko symulacyjne zrealizowano jako graf węzłowy oparty na bibliotece NetworkX (src/simulation/space.py). Liczbę węzłów każdego typu dobierano proporcjonalnie do liczności populacji N :

- **Gospodarstwa domowe:** $\lfloor N/4 \rfloor$ węzłów, cel: 4 agentów / dom,
- **Szkoły:** $\max(2, \lfloor N/30 \rfloor)$, cel: 25–30 uczniów / szkoła,
- **Biura:** $\max(3, \lfloor N/25 \rfloor)$, cel: 20–25 pracowników / biuro,
- **Sklepy:** $\max(2, \lfloor N/50 \rfloor)$,
- **Parki:** $\max(1, \lfloor N/100 \rfloor)$,
- **Placówki zdrowotne:** $\max(1, \lfloor N/200 \rfloor)$.

Takie skalowanie gwarantuje realistyczne zagęszczenie niezależnie od N i zapobiega efektowi „super-węzła” (ang. *super-node*) – problemu, w którym kilka biur obsługuje setki agentów jednocześnie.

3.2 Dzienny harmonogram agenta

Każdy agent wyznacza listę odwiedzanych węzłów metodą `_plan_day()`:

1. **Gospodarstwo domowe** – zawsze pierwsze; agenci tego samego domu dzielą ten węzeł przez całą dobę,
2. **Miejsce pracy / szkoła** – pomijane przy `lockdown=True`,
3. **Sklep** – z prawdopodobieństwem $p_{\text{shop}} = \min(1, 0,30 \cdot \text{contact_rate})$; pomijany przy `social_distance` i podczas lockdownu,
4. **Park** – z prawdopodobieństwem $p_{\text{park}} = \min(1, 0,18 \cdot \text{contact_rate})$ (0,08 przy dystansie społecznym); zablokowany podczas lockdownu.

Agent jest umieszczany jednocześnie we wszystkich wyznaczonych węzłach, co modeluje wielomiejscowy charakter dnia miejskiego.

3.3 Transmisja wewnątrz węzłów i poprawka MAX_CONTACTS

Transmisja wewnątrz węzła POI realizuje wzór (3) z modyfikatorem higieny:

$$h = 1 - 0,6 \cdot (\bar{\Theta}_H - 0,5), \quad p'_{\text{eff}} = p_{\text{eff}} \cdot h \quad (9)$$

gdzie $\bar{\Theta}_H = (\Theta_H^S + \Theta_H^I)/2$ to średni wskaźnik higieny pary kontaktowej. Wartość $h = 1,0$ przy $\bar{\Theta}_H = 0,5$ oznacza brak efektu; $h \in [0,70; 1,30]$ dla skrajnych przypadków.

Kluczową poprawką jest ograniczenie `MAX_INFECTIOUS_CONTACTS = 5`: każdy podatny agent losuje co najwyżej 5 spośród wszystkich zakaźnych agentów obecnych w węźle. Bez tej poprawki duże węzły (np. 20-osobowe biuro) z wieloma równocześnie zakaźnymi agentami generowały nierealistyczną kumulatywną siłę zakażenia $\lambda \gg 1$.

3.4 Kalibracja modelu

Nominalne wartości p_{base} z Tabeli 3 projektowane były z myślą o scenariuszach par (1 zakaźny, 1 podatny). W zaimplementowanym modelu węzłowym dokonano przeskalowania przez $p_{\text{mult}} = 0,16$, co prowadzi do `attack rate` $\approx 76\text{--}80\%$ przy braku interwencji. Odpowiadający temu współczynnik reprodukcji wyznaczono empirycznie (Sekcja 4.2) na $R_0 \approx 1,9$ – wartość na dolnej granicy zakresu typowego dla pandemicznych wirusów oddechowych [1]. Transmisję tranzytową wyłączono (`p_transit = 0`) po stwierdzeniu, że model grupowania tras w pierwotnej implementacji łączył wszystkich pasażerów podróżujących do danego typu POI (zamiast do tego samego konkretnego węzła), co powodowało artefaktywny $R_0 \gg 10$.

Czasy trwania faz. W zaimplementowanym modelu czasy przejść $E \rightarrow I$ oraz $I \rightarrow R/D$ pozostawiono jako wartości stałe (4 i 8 dni) – świadome uproszczenie ułatwiające kalibrację i testowanie. Zapowiadane w Etapie 1 losowanie tych czasów z rozkładu Gamma (Tabela 1) nie zostało wdrożone; wprowadzenie naturalnej wariancji biologicznej traktujemy jako kierunek dalszych prac (Sekcja 5).

3.5 Implementacja atrybutów behawioralnych

Wszystkie atrybuty opisane w Sekcji 2.3 zostały zaimplementowane i aktywnie wpływają na wyniki symulacji:

- `wears_mask` i `social_distancing` redukują p_{eff} zgodnie ze wzorami (5),
- `hygiene_score` $\in [0, 1]$ modyfikuje transmisję wzorem (9),
- `contact_rate` skaluje prawdopodobieństwo wizyt w sklepach i parkach (agenci o wysokim `contact_rate` odwiedzają więcej węzłów),
- `vaccinated` obniża podatność ($\text{immunity} = 0,5$) i zmniejsza ryzyko zgonu o 80%.

3.6 Interfejs użytkownika

Zrealizowano dwa interfejsy:


- **Streamlit dashboard** (`scripts/dashboard.py`) – statyczny: użytkownik ustawia parametry, uruchamia symulację, ogląda wykresy SEIRD i statystyki końcowe,
- **Real-time canvas** (`scripts/realtime_canvas.py`) – ciągła animacja agentów na kanwie HTML5; interwencje (lockdown, maseczki, dystans) stosowane *na żywo*, bez restartu symulacji.

3.7 Testy jednostkowe i analiza wrażliwości

Zestaw 25 testów pytest (`tests/`) weryfikuje:

- poprawność przejść kompartmentowych ($E \rightarrow I \rightarrow R/D$),
- zachowanie martwego agenta,
- wpływ szczepień na śmiertelność,
- blokowanie sklepów przy dystansie społecznym,
- blokowanie miejsc pracy podczas lockdownu,
- matematyczne właściwości funkcji `compute_p_eff` i `compute_node_transmission`.

Analiza wrażliwości (Rysunek 2) zbadała wpływ dwóch parametrów na wyniki symulacji. Mnożnik $p_{\text{mult}} \in [0,5; 1,5]$ silnie wpływa zarówno na szczyt zakaźnych, jak i na attack rate. Skuteczność maseczki $\eta_M \in [0,3; 0,7]$ ma wyraźny wpływ przy wysokim pokryciu maseczkami, natomiast przy niskim pokryciu ($< 30\%$) jej wpływ jest marginalny.



Rysunek 2: Analiza wrażliwości modelu: szczyt zakaźnych i attack rate w funkcji mnożnika p_{base} oraz skuteczności maseczki η_M . Pokrycie maseczkami: 50%, $N = 500$, 100 kroków, mediana 3 powtórzeń.

4 Etap 3: Właściwy eksperyment i projekt końcowy

Etap trzeci stanowi właściwą część badawczą projektu: siedem scenariuszy epidemicznych porównanych ilościowo pod kątem szczytowej liczby zakaźnych (*peak I*), sumarycznego wskaźnika zakażeń (attack rate) i liczby zgonów. Rozszerzeniem względem pierwotnego planu są dwa dodatkowe scenariusze: *lockdown reaktywny*, wprowadzony nie od pierwszego dnia, lecz dopiero po przekroczeniu progowego poziomu zakażeń (koszt opóźnionej reakcji służb publicznych), oraz *interwencje łączone* – realistyczny pakiet łagodnych środków stosowanych jednocześnie. Dodatkowo dla każdego scenariusza wyznaczono empiryczny przebieg efektywnego współczynnika reprodukcji $R_e(t)$ (Sekcja 4.2).

4.1 Metodologia eksperymentu

Każdy scenariusz uruchomiono $n = 7$ razy, aby zminimalizować stochastyczną wariancję wyników. Dla zapewnienia pełnej **odtwarzalności** każdy bieg korzysta ze stałego ziarna losowego ($seed = 12345 + \text{indeks biegu}$), co gwarantuje identyczne wyniki przy każdym uruchomieniu eksperymentu. Parametry bazowe symulacji: $N = 500$ agentów, inkubacja 4 dni, zakaźność 8 dni, $p_{death} = 0,02$, $p_{mult} = 0,16$, czas symulacji 180 kroków. Startowe zakażenia: 2% populacji w stanie I. Wykresy prezentują mediany przebiegów z pasmem IQR (25.–75. percentyl).

4.2 Empiryczny współczynnik reprodukcji $R_e(t)$

Zamiast jedynie zakładać wartość R_0 , wyznaczono ją *empirycznie* z przebiegu symulacji. Efektywny współczynnik reprodukcji $R_e(t)$ – średnią liczbę wtórnych zakażeń wywołanych przez jednego zakaźnego agenta w dniu t – oszacowano z zależności:


$$R_e(t) \approx \frac{\text{inc}(t)}{I(t)} \cdot T_I, \quad \text{inc}(t) = S(t-1) - S(t) \quad (10)$$

gdzie $\text{inc}(t)$ to dzienna zapadalność (liczba nowych zakażeń; ponieważ kompartment S maleje wyłącznie na rzecz E , jest ona równa spadkowi liczebności S), $I(t)$ – liczba aktywnie zakaźnych,

a $T_I = 8$ dni to czas zakaźności. Wartości wygładzono 9-dniową średnią ruchomą i maskowano dla $I < 5$ (eliminacja szumu przy wygasaniu epidemii).

Rysunek 3 przedstawia $R_e(t)$ dla kluczowych scenariuszy. Uśredniając $R_e(t)$ w fazie wczesnej (przed istotnym wyczerpaniem populacji podatnej) dla scenariusza bazowego, otrzymano **empiryczne** $R_0 \approx 1,9$. Wartość ta jest spójna z drugą, niezależną metodą – relacją rozmiaru końcowego epidemii $AR = 1 - e^{-R_0 \cdot AR}$, która dla attack rate $\approx 80\%$ daje $R_0 \approx 2,0$. Zgodność dwóch metod potwierdza, że model operuje w dolnej części zakresu pandemicznych wirusów oddechowych ($R_0 \in [2,0; 3,5]$).

Wykres ujawnia mechanikę poszczególnych interwencji: w scenariuszu bazowym $R_e(t)$ utrzymuje się powyżej 1 aż do ok. dnia 33 (wtedy wyczerpanie podatnych samoistnie zbija transmisję); lockdown natychmiastowy trzyma $R_e(t)$ trwale poniżej 0,5; lockdown reaktywny załamuje $R_e(t)$ poniżej 1 dokładnie w momencie aktywacji (dzień ≈ 9); interwencje łączone od startu utrzymują $R_e(t) \lesssim 1$. W scenariuszu szczepień widoczny jest późny pik wtórny $R_e(t)$, odpowiadający ognisku w grupie nieszczepionych.



Rysunek 3: Empiryczny efektywny współczynnik reprodukcji $R_e(t)$ dla wybranych scenariuszy (mediana 7 powtórzeń). Linia przerywana – próg epidemiczny $R_e = 1$; pionowa kropkowana – moment aktywacji lockdownu reaktywnego. Wczesnofazowe $R_0 \approx 1,9$.

4.3 Scenariusz 1: Bazowy – pandemia bez interwencji

Pandemia bez żadnych interwencji farmaceutycznych ani niemedycznych. Model rejestruje emergentną dynamikę SEIRD wynikającą wyłącznie ze struktury przestrzeni POI i parametrów biologicznych patogenu.

Wyniki: attack rate $\approx 79,7\%$, szczyt zakaźnych ($I_{\max} \approx 91$) osiągany ok. dnia 34, zgony ≈ 7 . Empiryczne $R_0 \approx 1,9$ (Sekcja 4.2), na dolnej granicy zakresu dla wirusów oddechowych [1].

4.4 Scenariusz 2a: Lockdown natychmiastowy

Pełny lockdown aktywowany od dnia 0 symulacji: zamknięcie wszystkich miejsc pracy (szkoły + biura) i sklepów. Agenci pozostają w gospodarstwach domowych; parki i placówki

zdrowotne pozostają otwarte.

Wyniki: attack rate spada do $\approx 3,5\%$ – redukcja o ponad 95% względem scenariusza bazowego. Szczyt zakaźnych $I_{\max} \approx 14$, zgony < 1 . Lockdown eliminuje główne drogi transmisji (biuro, szkoła), pozostawiając jedynie przeniesienie wewnątrzdomowe o ograniczonym zasięgu.


4.5 Scenariusz 2b: Lockdown reaktywny

Scenariusz ten modeluje *opóźnioną* reakcję służb publicznych: lockdown nie jest wprowadzany prewencyjnie, lecz dopiero po przekroczeniu progowego poziomu zakażeń $I_{\text{thr}} = 25$ agentów (5% populacji). Jest to model decyzji opartej na danych obserwacyjnych – analogicznie do sytuacji, gdy rząd ogłasza lockdown po pierwszym potwierdzeniu istotnego wzrostu hospitalizacji.

Implementacja: przed każdym krokiem symulacji zliczana jest aktualna liczba agentów w stanie I; gdy po raz pierwszy przekroczy I_{thr} , ustawiany jest atrybut `model.lockdown = True`, co blokuje miejsca pracy i sklepy od następnego dnia symulacji.

Wyniki: lockdown aktywował się średnio w dniu ≈ 9 , gdy epidemia zdążyła już zainfekować część populacji. Attack rate wyniosła $\approx 13,2\%$ (redukcja o $\approx 83\%$ vs. bazowy, lecz blisko czterokrotnie więcej niż przy lockdownie natychmiastowym), szczyt zakaźnych $I_{\max} \approx 38$ (dzień 13), zgony ≈ 2 .

Rysunek 4 zestawia krzywe dla trzech wariantów: brak interwencji, lockdown reaktywny i lockdown natychmiastowy. Opóźnienie zaledwie ≈ 9 dni powoduje wzrost attack rate z 3,5% do 13% – ilościowy dowód, że wczesna reakcja ma decydujące znaczenie.



Rysunek 4: Porównanie strategii lockdownu: brak / reaktywny (aktywacja dzień ≈ 9 , gdy $I \geq 25$) / natychmiastowy (od dnia 0). Opóźnienie ≈ 9 dni zwiększa attack rate blisko czterokrotnie.

4.6 Scenariusz 3: Kampania szczepień – 60% pokrycia

Zaszczepiono 60% populacji przed startem epidemii. Modelowana szczepionka jest *nie-szczelna* (*leaky*): obniża podatność o połowę ($\text{immunity} = 0,5$) i redukuje ryzyko zgonu o 80%, ale nie daje pełnej sterylizującej ochrony. Teoretyczny próg odporności stadnej dla $R_0 \approx 1,9$ wynosi $1 - 1/R_0 \approx 47\%$, jednak dotyczy on odporności *pełnej* – przy ochronie częściowej efektywna liczba uodpornionych jest znacznie niższa niż 60%.

Wyniki: attack rate $\approx 52,6\%$ (redukcja o $\approx 34\%$), szczyt zakaźnych $I_{\max} \approx 49$, zgony $\approx 3,6$ (redukcja o $\approx 51\%$). Mimo wysokiego pokrycia epidemia nie zostaje zatrzymana – w grupie niezaszczepionych tworzy się lokalny klaster transmisji (widoczny jako późny pik $R_e(t)$)

na Rys. 3). Kluczowy wniosek: nieszczelna szczepionka chroni przede wszystkim przed zgonem, w mniejszym stopniu przed samym zakażeniem.

4.7 Scenariusz 4: Superspreaderzy

5% populacji skonfigurowano jako superspreaderów: $\text{contact_rate} = 3,0$ (trzykrotnie wyższe prawdopodobieństwo wizyt w sklepach i parkach) oraz $\text{hygiene_score} = 0,1$ (słaba higiena $\rightarrow$ wyższe p_{eff}). Pozostała populacja: wartości domyślne.

Wyniki: $\text{attack rate} \approx 79,3\%$ (praktycznie równy bazowemu), szczyt zakaźnych $I_{\text{max}} \approx 100$ (vs. 91 w bazowym, +10%), zgony ≈ 9 . Na pierwszy rzut oka efekt superspreaderów wydaje się znikomy, jednak to artefakt *efektu sufitu*: scenariusz bazowy jest już niemal nasycony ($\text{attack rate} \approx 80\%$), więc nie ma „miejsca” na wzrost zasięgu. Rzeczywisty wpływ superspreaderów ujawnia się w innych miarach: **wyższy i ostrzejszy szczyt** (I_{max} o 10% większy) oraz większa liczba zgonów. Mała grupa (25 agentów na 500) napędza nieproporcjonalnie dużą część transmisji, zgodnie z zasadą 80/20 w epidemiologii [7]. Pełne ujawnienie tego efektu wymagałoby reżimu nienasyconego (np. przy umiarkowanych interwencjach) – co odnotowujemy jako kierunek dalszych prac (Sekcja 5).

4.8 Scenariusz 5: Wpływ higieny rąk

Porównano trzy populacje różniące się rozkładem Θ_H :

- niska higiena ($\bar{\Theta}_H = 0,15$): $\text{attack rate} \approx 83,7\%$, $I_{\text{max}} \approx 118$, szczyt dzień 30,
- higiena bazowa ($\bar{\Theta}_H = 0,50$): $\text{attack rate} \approx 76,1\%$, $I_{\text{max}} \approx 91$, szczyt dzień 35,
- wysoka higiena ($\bar{\Theta}_H = 0,85$): $\text{attack rate} \approx 64,4\%$, $I_{\text{max}} \approx 66$, szczyt dzień 39.

Wzrost $\bar{\Theta}_H$ z 0,15 do 0,85 obniża attack rate o ≈ 19 p.p., redukuje szczyt zakaźnych o ponad 40% i opóźnia go o ≈ 9 dni. Wysoka higiena samodzielnie nie eliminuje epidemii ($R_e > 1$ nadal we wczesnej fazie), lecz wyraźnie spłaszcza krzywą zakaźnych (ang. *flatten the curve*).

4.9 Scenariusz 6: Interwencje łączone

Wszystkie poprzednie scenariusze badały interwencje w izolacji. Scenariusz 6 modeluje *realistyczny pakiet* łagodnych środków stosowanych jednocześnie – tak, jak wygląda rzeczywista polityka zdrowia publicznego: 50% populacji w maseczkach, podniesiona higiena ($\bar{\Theta}_H = 0,70$) oraz umiarkowane pokrycie szczepieniami (40%). Żaden z tych środków z osobna nie jest szczególnie silny.


Wyniki: $\text{attack rate} \approx 11,7\%$ (redukcja o $\approx 85\%$ względem bazowego), szczyt zakaźnych $I_{\text{max}} \approx 16$ (dzień 11), zgony < 1 . Efekt jest **silnie nieliniowy** (synergiczny): złożenie trzech łagodnych interwencji daje skuteczność porównywalną z lockdownem reaktywnym ($\text{attack rate } 13,2\%$), lecz *bez* zamykania miejsc pracy, szkół i sklepów. Krzywa $R_e(t)$ (Rys. 3) od początku utrzymuje się poniżej 1, co oznacza wygaszanie epidemii od pierwszego dnia. To najważniejszy wniosek praktyczny eksperymentu: skoordynowany pakiet umiarkowanych środków może zastąpić drażniący lockdown przy znikomym koszcie społeczno-gospodarczym.

4.10 Wyniki zbiorcze

Tabela 5 zestawia mediany wszystkich miar dla siedmiu scenariuszy. Rysunek 5 prezentuje krzywe SEIRD dla każdego scenariusza, Rysunek 6 słupkowe porównanie kluczowych wskaźników, a Rysunek 7 szczegółowe porównanie poziomów higieny.

Tabela 5: Zbiorcze wyniki eksperymentów Stage 3 ($N = 500$, 7 powtórzeń, 180 kroków, ziarno=12345)

Scenariusz	Attack rate	Peak I	Dzień szczytu	Zgony
Bazowy (brak interwencji)	79,7%	91	34	7
Lockdown natychmiastowy (d. 0)	3,5%	14	8	< 1
Lockdown reaktywny (d. ≈ 9)	13,2%	38	13	2
Szczepienia (60%)	52,6%	49	31	4
Superspreaderzy (5%)	79,3%	100	35	9
Wysoka higiena ($\bar{\Theta}_H=0,85$)	61,7%	63	43	7
Interwencje łączone	11,7%	16	11	< 1




Rysunek 5: Krzywe SEIRD dla siedmiu scenariuszy Stage 3 (siatka 2×4). Linie ciągłe – mediana 7 powtórzeń; pasma – IQR. Pionowa przerywana w Sc. 2b oznacza moment aktywacji lockdownu.


5 Ograniczenia i kierunki dalszych prac

Świadoma identyfikacja ograniczeń jest elementem rzetelności pracy modelarskiej. Najważniejsze uproszczenia obecnej implementacji oraz wynikające z nich kierunki rozwoju:

- **Stałe czasy trwania faz.** Okresy inkubacji i zakaźności są wartościami stałymi (4 i 8 dni). Wprowadzenie losowania z rozkładu Gamma (zob. Tab. 1) dodałoby naturalną wariancję biologiczną – dłuższy ogon zakażeń i bardziej miękkie krzywe epidemiczne.
- **Brak modelu pojemności służby zdrowia.** Węzły zdrowotne istnieją, lecz nie mają ograniczonej pojemności. Dodanie progu przeciążenia szpitali i miary „osobodni ponad pojemnością” wzmocniłoby argument o „spłaszczaniu krzywej”.



Rysunek 6: Porównanie kluczowych wskaźników: szczyt zakaźnych, attack rate i liczba zgonów dla siedmiu scenariuszy. Słupki błędów: odchylenie standardowe między powtórzeniami.



Rysunek 7: Wpływ poziomu higieny rąk (Θ_H) na przebieg epidemii: krzywe zakaźnych (lewo) i porównanie wskaźników (pravo) dla trzech populacji.

- **Skończony rozmiar populacji.** $N = 500$ wprowadza efekty skończonego rozmiaru (stochastyczne wygasanie, szum $R_e(t)$ przy małym I). Wskazane jest badanie skalowania wyników z N .
- **Efekt sufitu przy wysokim attack rate.** Wpływ niektórych czynników (np. superspreaderów) jest maskowany przez nasycenie scenariusza bazowego; ich pełna ocena wymaga reżimu nienasyconego.
- **Uproszczony model odporności.** Szczepionka jest nieszczelna i stała w czasie – brak modelu zanikania odporności (*waning*) i reinfekcji, istotnych dla dynamiki wielofalowej.
- **Pojedynczy patogen i brak realnej topografii.** Architektura (pliki YAML, rozszerzenie mesa-geo) jest przygotowana na wymianę patogenu i integrację z rzeczywistą siecią GIS/OpenStreetMap, co stanowi naturalny następny krok.
- **Przegląd przestrzeni parametrów.** Pojedyncze punkty (60% szczepień, 50% maseczek) warto zastąpić przeglądem ciągłym (sweep), by empirycznie wyznaczyć np. próg pokrycia szczepień dławiący epidemię.

6 Podsumowanie i wnioski

Niniejszy dokument dokumentuje kompletną, trójstopniową realizację wieloskalowej symulacji agentowej rozprzestrzeniania się pandemii wirusowej.

Wnioski z Etapu 1

Prototyp MVP zrealizował model SEIRD na siatce 50×50 z losowym ruchem agentów, uzyskując emergentne $R_0 \approx 2,6$ – wartość zgodną z danymi epidemiologicznymi. Architektura kodu jest poprawna i rozszerzalna. (Docelowy model węzłowy z Etapu 2/3 ma odmienną topologię kontaktów, stąd jego niezależnie zmierzone $R_0 \approx 1,9$ – Sekcja 4.2 – różni się od wartości prototypu siatkowego.)

Wnioski z Etapu 2

Przejsie na środowisko węzłów POI wymagało rozwiązania nietrywialnych problemów kalibracyjnych: (a) skalowanie liczby węzłów z N zapobiega efektowi super-węzła, (b) ograniczenie `MAX_INFECTIOUS_CONTACTS = 5` eliminuje artefaktualną saturację, (c) naprawa grupowania tras tranzytowych usuwa błąd o rzędzie wielkości w efektywnym R_0 . Zestaw 25 testów automatycznych weryfikuje poprawność każdego komponentu.

Wnioski z Etapu 3

Współczynnik reprodukcji wyznaczono empirycznie dwiema niezależnymi metodami (odtworzenie $R_e(t)$ oraz relacja rozmiaru końcowego), otrzymując zgodne $R_0 \approx 1,9$. Wyniki eksperymentów prowadzą do sześciu wniosków epidemiologicznych:

1. **Lockdown natychmiastowy jest najskuteczniejszą pojedynczą interwencją:** redukcja attack rate z $\approx 80\%$ do $3,5\%$ – efekt przecięcia wszystkich pozadomowych ścieżek transmisji od pierwszego dnia ($R_e(t)$ trwale poniżej $0,5$).

2. **Koszt opóźnienia lockdownu jest nieproporcjonalnie wysoki:** opóźnienie zaledwie ≈ 9 dni (do przekroczenia progu $I \geq 5\%$) powoduje wzrost attack rate z 3,5% do 13% – blisko czterokrotny. Każdy dzień zwłoki lawinowo powiększa zasięg.
3. **Pakiet łagodnych interwencji może zastąpić lockdown:** połączenie maseczek (50%), higieny i częściowych szczepień (40%) redukuje attack rate do $\approx 12\%$ – niemal tyle, co lockdown reaktywny, lecz *bez* zamykania gospodarki. Efekt jest synergiczny (nieliniowy), niewidoczny przy badaniu środków osobno.
4. **Nieszczelne szczepienia chronią głównie przed zgonem:** przy 60% pokryciu attack rate spada do $\approx 53\%$, ale zgony redukowane są o $\approx 51\%$. W populacji niezaszczepionych tworzy się klaster transmisji (późny pik $R_e(t)$).
5. **Superspreaderzy podnoszą szczyt, lecz attack rate maskuje efekt sufitu:** 5% populacji o wysokim contact_rate i niskim Θ_H zwiększa $I_{\max}$ o $\approx 10\%$; brak wzrostu attack rate wynika z nasycenia scenariusza bazowego, nie z braku wpływu (zasada 80/20 [7]).
6. **Higiena rąk spłaszcza krzywą, ale nie eliminuje epidemii:** przejście z $\bar{\Theta}_H = 0,15$ do 0,85 obniża attack rate o ≈ 19 p.p., redukuje szczyt o ponad 40% i opóźnia go o ≈ 9 dni. Samodzielna poprawa higieny nie wystarcza przy $R_e > 1$.

Całościowy projekt potwierdza, że podejście agentowe pozwala badać heterogeniczne efekty interwencji epidemicznych, niedostępne w klasycznych modelach ODE – w szczególności wpływ rozkładu indywidualnych cech (contact_rate, hygiene_score) na makroskopową dynamikę zarazy.

Bibliografia

- [1] R. M. Anderson i R. M. May. *Infectious Diseases of Humans: Dynamics and Control*. Oxford University Press, 1992.
- [2] E. Bonabeau. „Agent-based modeling: Methods and techniques for simulating human systems”. W: *Proceedings of the National Academy of Sciences* 99 (2002), s. 7280–7287. DOI: [10.1073/pnas.082080899](https://doi.org/10.1073/pnas.082080899).
- [3] F. Brauer. „Compartmental Models in Epidemiology”. W: *Mathematical Epidemiology. Lecture Notes in Mathematics* 1945 (2008), s. 19–79. DOI: [10.1007/978-3-540-78911-6_2](https://doi.org/10.1007/978-3-540-78911-6_2).
- [4] S. Eubank, H. Guclu, V. S. A. Kumar, M. V. Marathe, A. Srinivasan, Z. Toroczkai i N. Wang. „Modelling disease outbreaks in realistic urban social networks”. W: *Nature* 429 (2004), s. 180–184. DOI: [10.1038/nature02541](https://doi.org/10.1038/nature02541).
- [5] J. Kazil, D. Masad i A. Crooks. *Utilizing Python for Agent-Based Modeling: The Mesa Framework*. 2020. DOI: [10.1007/978-3-030-61255-9_30](https://doi.org/10.1007/978-3-030-61255-9_30).
- [6] W. O. Kermack i A. G. McKendrick. „A Contribution to the Mathematical Theory of Epidemics”. W: *Proceedings of the Royal Society of London A* 115.772 (1927), s. 700–721. DOI: [10.1098/rspa.1927.0118](https://doi.org/10.1098/rspa.1927.0118).
- [7] A. L. Lloyd. „Realistic Distributions of Infectious Periods in Epidemic Models: Changing Patterns of Persistence and Dynamics”. W: *Theoretical Population Biology* 60 (2001), s. 59–71. DOI: [10.1006/tpbi.2001.1525](https://doi.org/10.1006/tpbi.2001.1525).

- [8] M. Tracy, M. Cerdá i K. M. Keyes. „Agent-Based Modeling in Public Health: Current Applications and Future Directions”. W: *Annual Review of Public Health* 39 (2018), s. 77–94. DOI: [10.1146/annurev-publhealth-040617-014317](https://doi.org/10.1146/annurev-publhealth-040617-014317).
- [9] L. Willem, F. Verelst, J. Bilcke, N. Hens i P. Beutels. „Lessons from a decade of individual-based models for infectious disease transmission: a systematic review”. W: *BMC Infectious Diseases* 17 (2017), s. 612. DOI: [10.1186/s12879-017-2699-8](https://doi.org/10.1186/s12879-017-2699-8).
- [10] J. Zhang i in. „Changes in contact patterns shape the dynamics of the COVID-19 outbreak in China”. W: *Science* 368 (2020), s. 1481–1486. DOI: [10.1126/science.abb8001](https://doi.org/10.1126/science.abb8001).